Санкт-Петербургский государственный университет

Выпускная квалификационная работа

Реализация библиотеки примитивов разреженной линейной алгебры с поддержкой вычислений на GPU

Орачев Егор Станиславович

Уровень образования: магистратура
Направление 09.04.04 «Программная инженерия»
Основная образовательная программа ВМ.5666.2021 «Программная инженерия»

Научный руководитель:
доцент кафедры информатики, к.ф.-м.н С.В. Григорьев

Рецензент:
эксперт, ООО “Техкомпания Хуавей” С.В. Моисеев

Введение

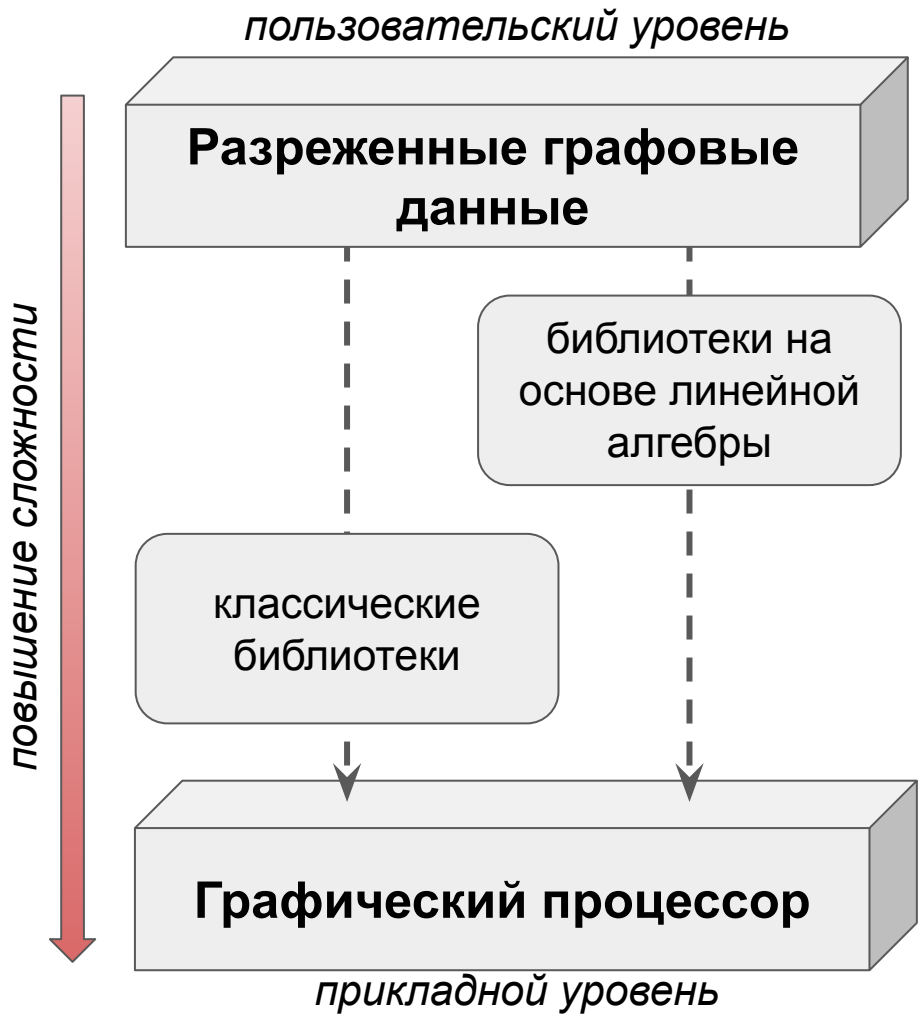

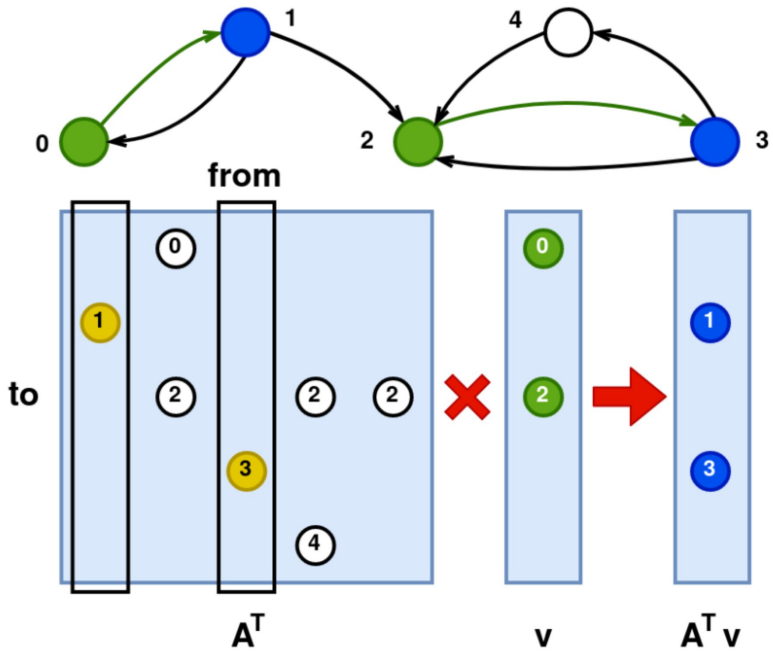

Рисунок: Обход графа с использованием произведения матрицы на вектор

Цель и задачи

Цель данной работы – реализация библиотеки примитивов обобщенной разреженной линейной алгебры с переносимой, высокопроизводительной и не специфичной для производителя поддержкой вычислений на видеокарте.

Для достижения цели были поставлены следующие задачи:

- Провести обзор предметной области
- Разработать архитектуру библиотеки
- Реализовать библиотеку в соответствии с разработанной архитектурой
- Провести экспериментальное исследование производительности полученных артефактов

Существующие решения

Решения для анализа графов:

- *SuiteSparse GraphBLAS и LaGraph, Huawei GraphBLAS, IBM GraphBLAS*
- *GraphBLAST, GBTL*
- *Gunrock, CuSha, MapGraph, Medusa*

Математические библиотеки разреженной линейной алгебры:

- *cuSPARSE*
- *clSPARSE*
- *bhSPARSE*
- *Cusp*

Предлагаемое решение

Проект Spla – библиотека примитивов разреженной линейной алгебры.

Принципы разработки:

- Опциональность ускорения вычислений
- Пользовательские поэлементные функции
- Предопределенные скалярные типы данных
- Гибридный формат хранения данных
- Экспортируемый интерфейс
- Интроспекция

Архитектура библиотеки

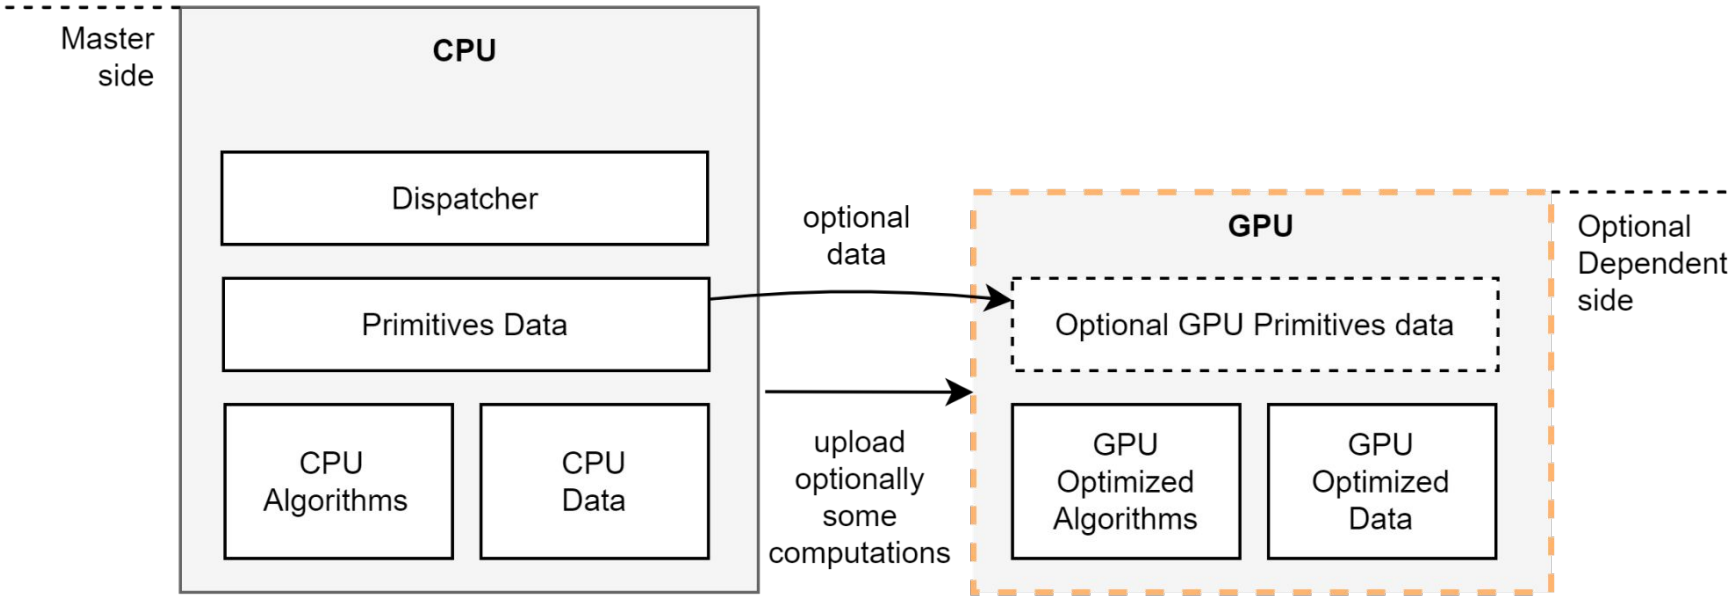

Рисунок: Высокоуровневый дизайн библиотеки *Spla*. Сторона библиотеки на CPU контролирует общую работу и способна функционировать самостоятельно. Вычисления на GPU опциональны. Алгоритмы и хранилище данных опциональны

Детали реализации

- **Технологии**
  - C++17, CMake, OpenCL 1.2
- **Форматы хранения данных**
  - Векторные: DoK, Dense (CPU/GPU), COO (CPU/GPU)
  - Матричные: DoK, LiL, CSR (CPU/GPU)
- **Операции линейной алгебры**
  - Masked SpV x SpM
  - Masked SpM x V
  - Masked SpM x SpM^T
- **Алгоритмы на графах**
  - BFS, SSSP, PR, TC

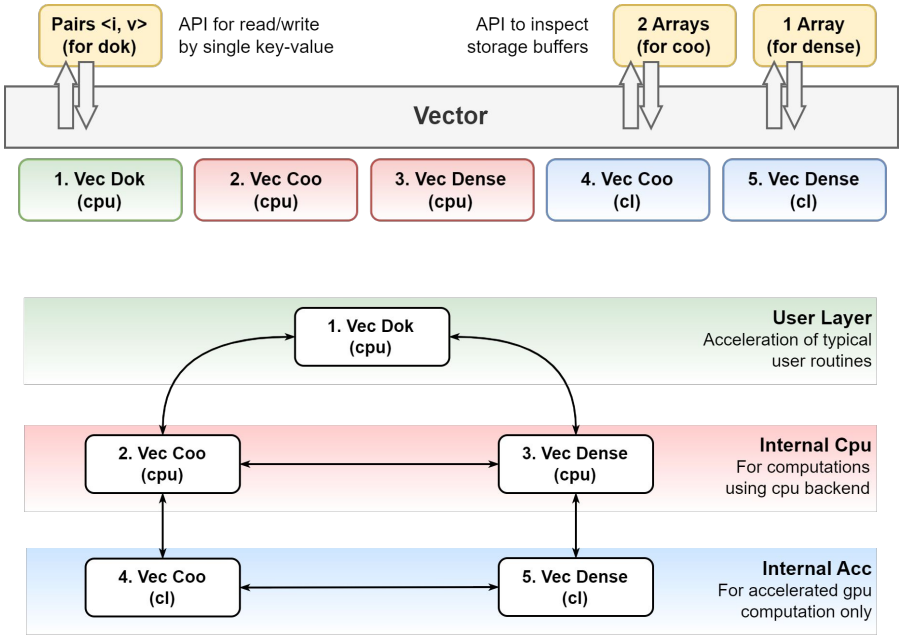

Рисунок: Гибридное хранилище данных на примере контейнера Вектор

Пример использования

```
SPLA_API Status spla::bfs(const ref_ptr<Vector>&     v,
                          const ref_ptr<Matrix>&     A,
                          uint                       s,
                          const ref_ptr<Descriptor>& desc) {
    const auto N = v->get_n_rows();

    ref_ptr<Vector> front_prev     = make_vector(N, INT);
    ref_ptr<Vector> front          = make_vector(N, INT);
    ref_ptr<Scalar> front_size     = make_int(1);
    ref_ptr<Scalar> depth          = make_int(1);
    ref_ptr<Scalar> zero           = make_int(0);
    int             current_level  = 1;

    front_prev->set_int(s, 1);

    while (!(front_size->as_int() == 0)) {
        depth->set_int(current_level);

        exec_v_assign_masked(v, front_prev, depth, SECOND_INT, NQZERO_INT, desc);
        exec_vxm_masked(front, v, front_prev, A, BAND_INT, BOR_INT, EQZERO_INT, zero, desc);
        exec_v_reduce(front_size, zero, front, PLUS_INT, desc);

        current_level += 1;

        std::swap(front_prev, front);
    }

    return Status::Ok;
}
```

Фрагмент кода: Реализация алгоритма поиска в ширину (BFS) с использованием C++ API библиотеки *Spla*

Экспериментальное исследование

Исследовательские вопросы:

- **B1**: *Какова производительность разработанной библиотеки в сравнении с существующими решениями на GPU?*
- **B2**: *Какова производительность и каково масштабирование решения на GPU различных производителей?*
- **B3**: *Какова производительность решения на встроенных GPU в сравнении с существующими CPU инструментами?*

Алгоритмы: BFS, SSSP, PR, TC

Инструменты: *Gunrock, GraphBLAST, LaGraph (SuiteSparse), Spla*

Набор данных

Graph	Vertices	Edges	Out Degree		
			Avg	Sd	Max
coAuthorsCit	227.3K	1.6M	7.2	10.6	1.4K
coPapersDBLP	540.5K	30.5M	56.4	66.2	3.3K
amazon2008	735.3K	7.0M	9.6	7.6	1.1K
hollywood2009	1.1M	112.8M	98.9	271.9	11.5K
comOrkut	3.1M	234.4M	76.3	154.8	33.3K
citPatents	3.8M	33.0M	8.8	10.5	793.0
socLiveJournal	4.8M	85.7M	17.7	52.0	20.3K
indochina2004	7.4M	302.0M	40.7	329.6	256.4K
belgiumosm	1.4M	3.1M	2.2	0.5	10.0
roadNetCA	2.0M	5.5M	2.8	1.0	12.0
rggn222s0	4.2M	60.7M	14.5	3.8	36.0
rggn223s0	8.4M	127.0M	15.1	3.9	40.0
roadcentral	14.1M	33.9M	2.4	0.9	8.0

Таблица: Набор данных для эксперимента. Тринадцать матриц графов из коллекции разреженных матриц университета Флориды

B1: Сравнение производительности

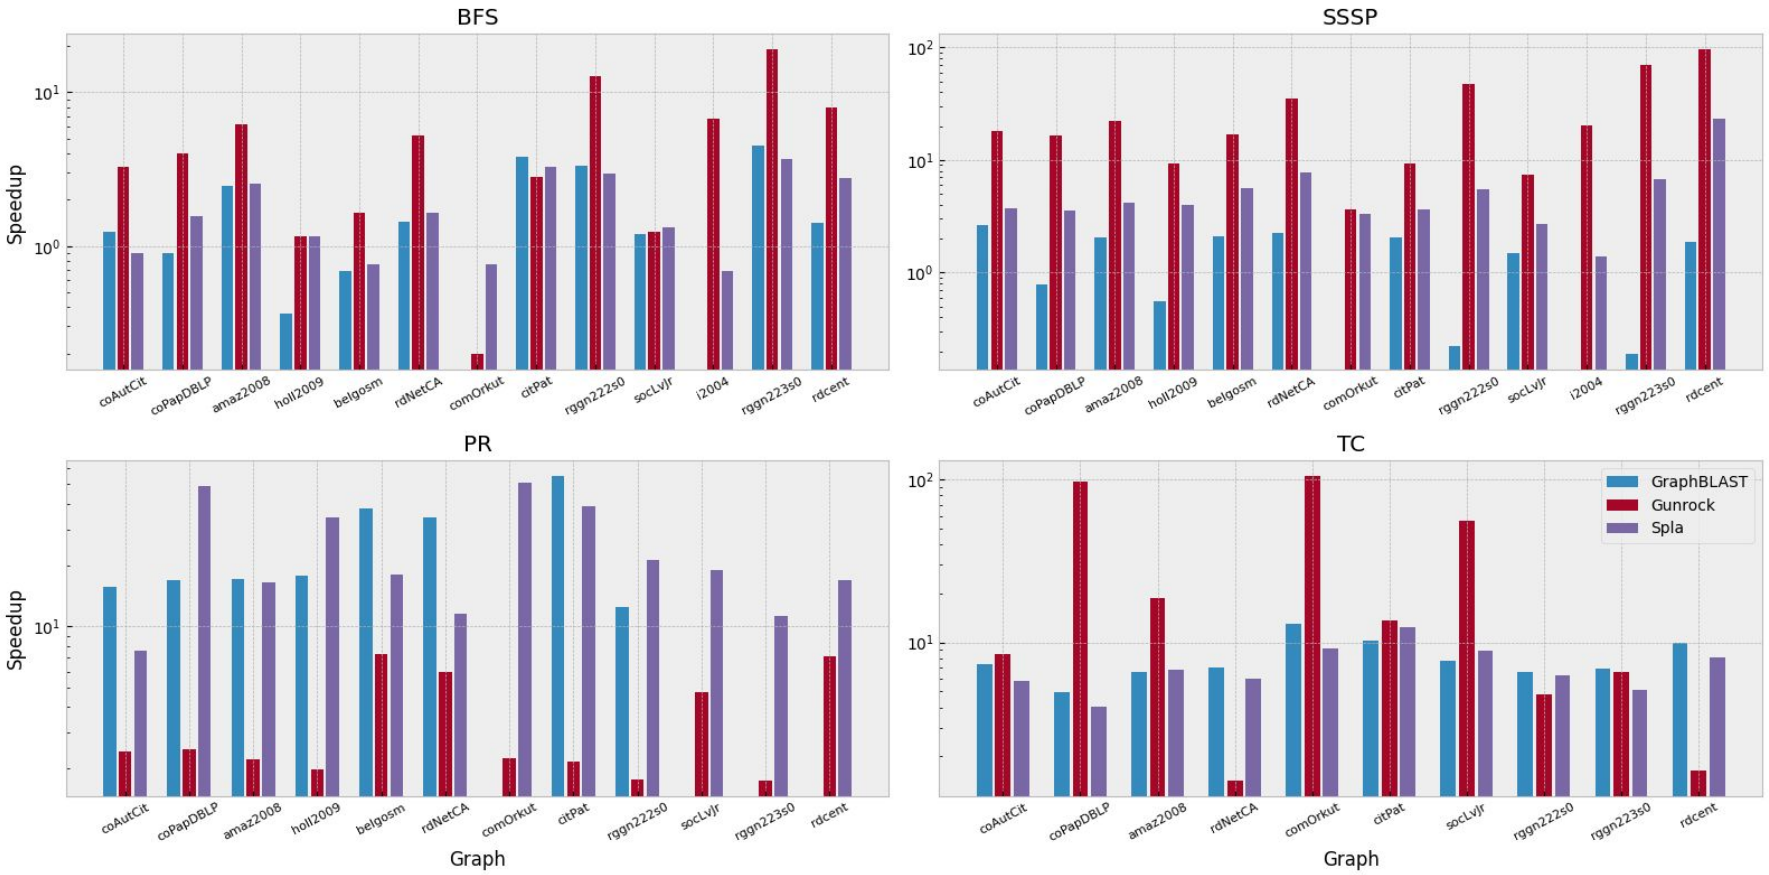

График: Сравнение производительности *GraphBLAST*, *Gunrock*, *Spla* относительно *LaGraph* (*SuiteSparse*). Логарифмический масштаб. Конфигурация: Ubuntu 20.04, Core i7-6700 4-core, DDR4 64Gb, GeForce GTX 1070, 8Gb VRAM

B2: Масштабируемость и переносимость

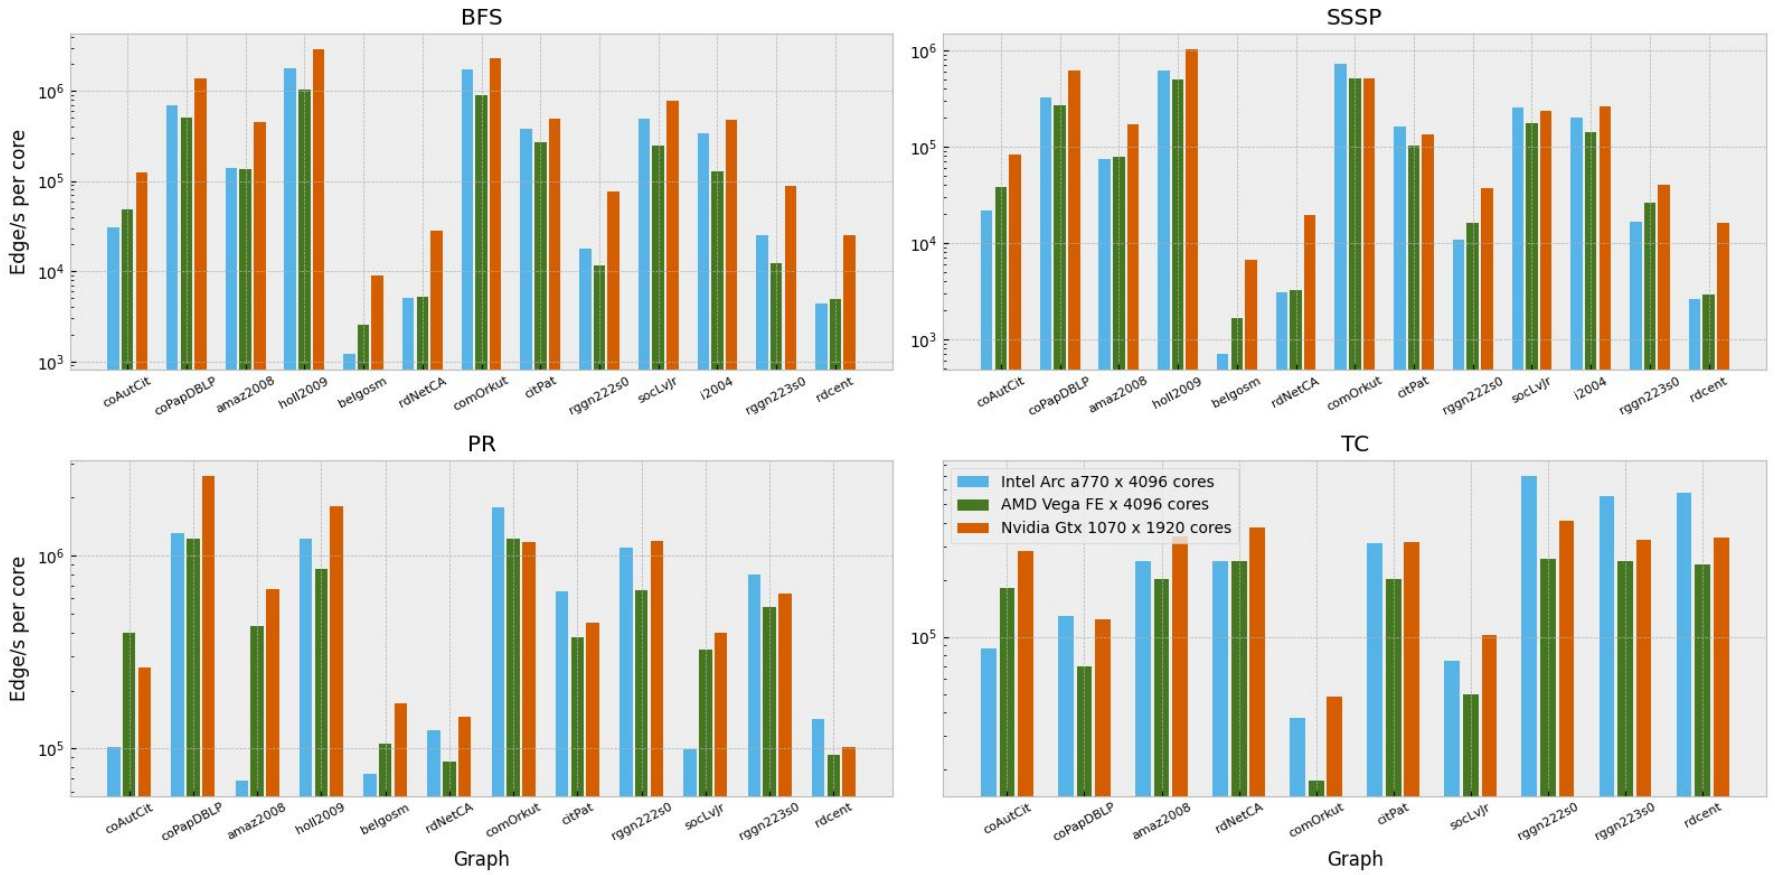

График: Производительность *Spla* библиотеки как число ребер/сек. на ядро GPU. Логарифмический масштаб. Конфигурация: GeForce GTX 1070 with 8Gb VRAM, Arc A770 with 8GB VRAM and Radeon Vega FE with 16GB VRAM

B3: Производительность на встроенных GPU

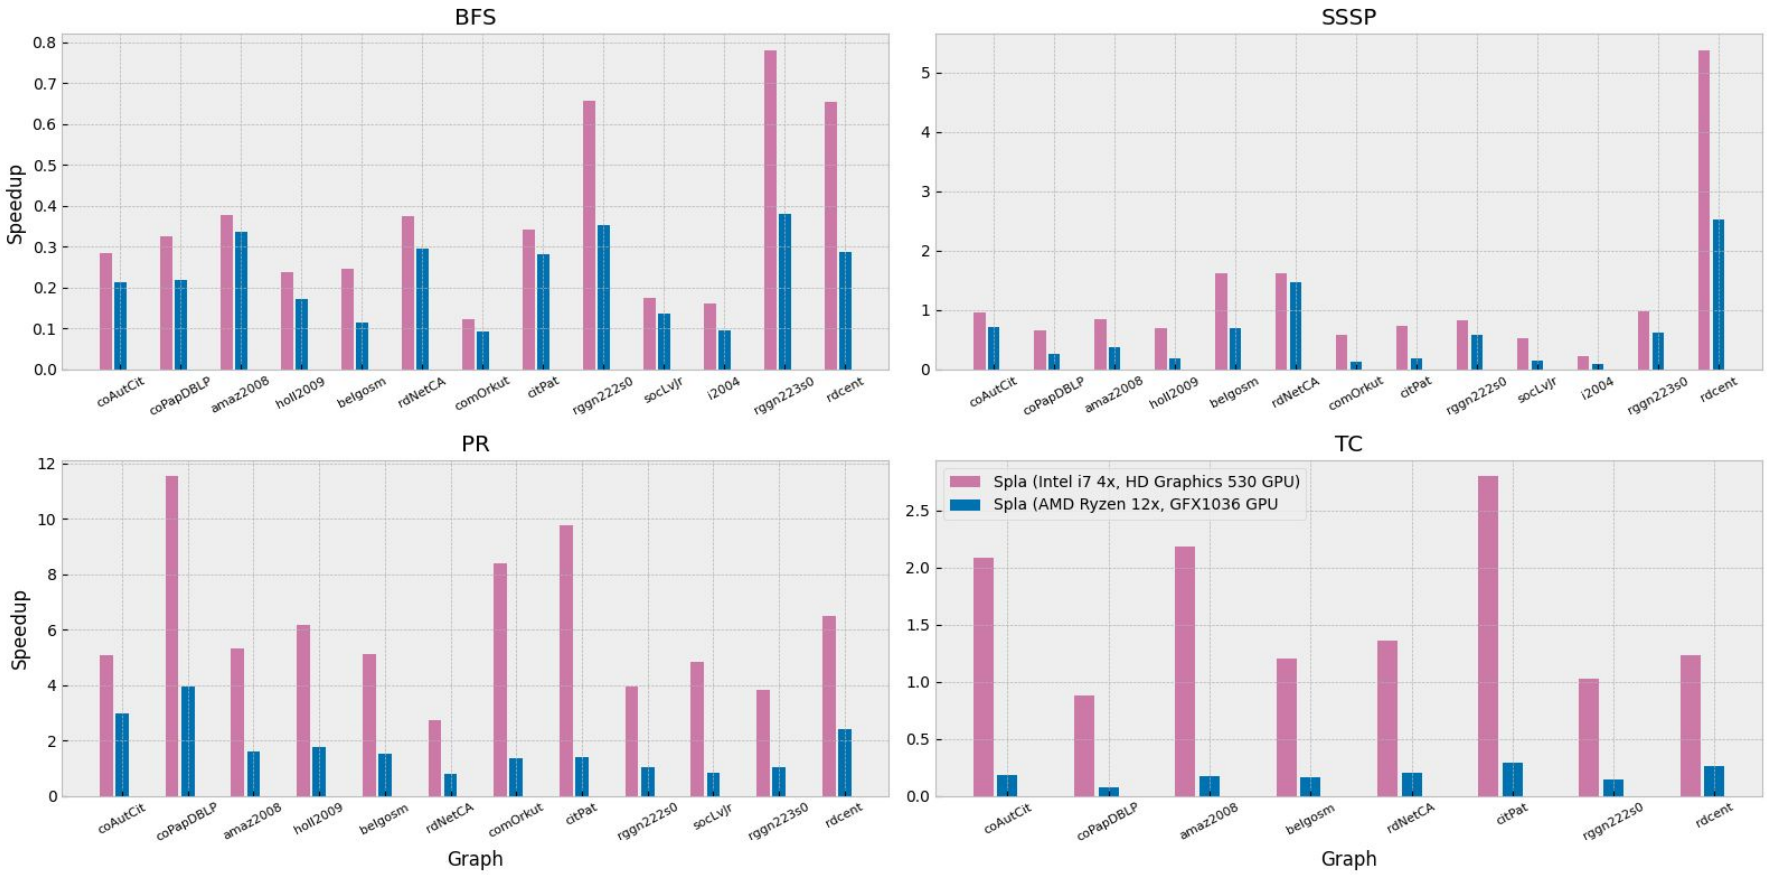

График: Ускорение *Spla* библиотеки на интегрированной GPU относительно *LaGraph* (*SuiteSparse*) на CPU. Конфигурация: Ubuntu 20.04, Core i7-6700, DDR4 64Gb, HD Graphics 530 GPU and Ubuntu 22.04, Ryzen 9 7900x, DDR4 128 GB, GFX1036 GPU

Заключение

В ходе данной работы были получены следующие результаты:

- Проведен обзор предметной области
- Разработана архитектура библиотеки примитивов разреженной линейной алгебры с поддержкой вычислений на GPU
- Реализована библиотека в соответствии с разработанной архитектурой. Исходный код проекта опубликован на платформе GitHub. Он доступен по ссылке github.com/SparseLinearAlgebra/spla
- Выполнено экспериментальное исследование производительности полученных артефактов. Полученное решение **сравнимо** с *GraphBLAST*, в некоторых случаях до **36** раз быстрее, и стабильно **быстрее** *SuiteSparse*, в некоторых случаях до **20** раз быстрее